ХАКАТОН FREEDOM BROKER · КОМАНДА SAW-CELL

CQA — Conversation Quality Analytics

Автоматическая оценка работы операторов в чатах и звонках по настраиваемому чек-листу — с доказательствами, апелляциями и пересчётом итога.

Азамат · Нурлат · Алдияр

2026

ЗАДАЧА

Ручной контроль качества не масштабируется

Как сейчас

- Проверяющий читает чат или слушает звонок целиком
- Выборочная проверка — малая доля диалогов
- Оценки разных людей расходятся, обоснования нет
- Спорить с оценкой сложно — непонятно, на что ссылаться

Что делает CQA

- Оценивает **каждый** диалог по 8 критериям официального чек-листа
- Каждый ответ — с обоснованием и ссылкой на реплику / момент записи
- Оператор подаёт апелляцию, проверяющий решает, итог пересчитывается
- RU / KZ / EN, чаты и звонки, итог 0–100

КАК ЭТО РАБОТАЕТ

Путь диалога от API до итоговой оценки

1. Импорт

Диалоги из API организаторов по `group_id`. Звонки расшифровываются (faster-whisper / Gemini).

→

2. Очередь

Express + SQLite. Задания оцениваются параллельно, настройки модели фиксируются.

→

3. Факты кодом

Паузы, первая реакция, ожидание, идентификация — считаются без модели.

→

4. Модель

Промпт из активного чек-листа + факты. Qwen локально или Gemini.

→

5. Проверка

Ответ валидируется кодом. Ошибка → 1 повтор с обратной связью.

→

6. Итог

Баллы по весам, N/A с перераспределением, флаг грубой ошибки.

Сервер

Express API, встроенный `node:sqlite`, очередь, расчёт, апелляции, экспорт.

AI-слой

Промпт, правила по критериям, провайдеры Ollama/Gemini, валидация, расшифровка.

Интерфейс

Чистый HTML/CSS/JS, готов к встраиванию в Dynamics 365.

ОЦЕНКА ОДНОГО ДИАЛОГА

Модель не выдумывает — каждое её слово проверяется

Строгая валидация

ID реплик существуют, значение из шкалы, N/A — только где разрешено, для «Нет» указан проверенный участок.

Повтор, не подмена

Невалидный ответ → одна попытка с обратной связью → явная ошибка. Выдуманных оценок нет.

Проверка цитат

Цитаты, которых нет в диалоге, получают бейдж

Требует проверки

Защита от prompt injection

Текст диалога передаётся модели как недоверенные данные.

Самосогласованность

LLM_SAMPLES=3: несколько прогонов и голосование по да/нет/N/A, нижняя медиана по шкале.

```
c04 · Консультация · Нет · 0 / 20
«Оператор не ответил про комиссию, см. m010»
→ клик по m010 прокручивает чат к реплике
```

ЧЕК-ЛИСТ

8 критериев, веса и N/A — всё настраивается

КРИТЕРИЙ	ВЕС	N/A
c01 · Установление контакта	10	—
c02 · Выявление потребности	15	можно
c03 · Идентификация	20	можно
c04 · Консультация	20	можно
c05 · Эмпатия	15	—
c06 · Управление диалогом	15	—
c07 · Завершение	5	можно
c08 · Грубые ошибки	**флаг**	—

Промпт строится из чек-листа

Критерии нигде не захардкожены — промпт собирается из активной версии.

Редактор версий

Заменили критерий → новая версия → модель переоценивает **только изменённые** критерии.

Расчёт итога

Шкала → баллы по весу, N/A исключается с перераспределением, округление до 2 знаков.

ДОКАЗАТЕЛЬСТВА И АПЕЛЛЯЦИИ

Каждую оценку можно проверить и оспорить

Оценка
Ответ, баллы, вес и обоснование по каждому критерию

→

Доказательство
Клик по реплике → прокрутка чата или перемотка записи звонка

→

Апелляция
Оператор оспаривает критерий и оставляет комментарий

→

Решение
Проверяющий видит фрагмент, подтверждает или меняет оценку

→

Новый итог
Пересчёт; исходная оценка модели сохраняется

Прозрачность

Оператор видит, за что снят балл, а не только цифру.

История

Оценка модели и решение человека хранятся раздельно — можно мерить точность.

Звонки

Плеер с переходом к нужному фрагменту записи по метке времени.

МОДЕЛИ

Свой GPU или облако — одна переменная

LLM_PROVIDER=ollama

Qwen3.6-35B-A3B локально

NVIDIA L40S + Ollama. Данные не покидают контур, $0 за вызов — платится только аренда GPU.

LLM_PROVIDER=gemini

Gemini 3.1 Flash Lite

Облако без своего железа. Стоимость считается по токенам каждого вызова и видна в интерфейсе.

LLM_PROVIDER=auto

Автоматически

Qwen, пока GPU-сервер отвечает (проверка каждые 20 с), иначе Gemini. Модель записывается в каждую оценку.

Расшифровка звонков

faster-whisper на том же GPU или Gemini audio — звонок превращается в реплики с метками времени и оценивается так же, как чат.

ТОЧНОСТЬ

Сверка с ручной разметкой 65 DEV-диалогов

96%

совпадение по критериям с разметкой

2.6

средняя ошибка итога (MAE) по шкале 0–100

100%

точность флага грубых ошибок

6.7

МИН

на все 65 диалогов, локально на L40S

Модель: Qwen3.6-35B-A3B (Q4), промпт v16, `npm run eval`. Честно: разметку делала команда, и промпт улучшался на этих же диалогах — на новых данных точность ожидаемо ниже. Отчёты — `eval/reports/`.

ДЕМО И СДАЧА

Что можно посмотреть за 5 минут

1 · Диалоги

Импорт по group_id, фильтры по языку, каналу и итогу.

2 · Карточка

8 критериев, обоснование, переход к реплике или моменту звонка.

3 · Апелляция

Оспорить → решение проверяющего → пересчёт.

4 · Чек-лист

Новая версия критерия и точечная переоценка.

5 · Сдача жюри

Полнота, ошибки, готовый `results.json` (JSON 1.0, строгая проверка).

```
npm run prod -- --group_id=<id>
импорт → оценка → экспорт → валидация
```

КОМАНДА SAW-CELL

Спасибо!

Азамат

Сервер, БД, расчёт итога, интеграция, GPU-контур

Нурлат

Интерфейс и UX

Алдияр

Оценка моделью, промпт, метрика точности